

计算机视觉的部分基础知识

王啸峰 from UCAS & CASIA

2021 年 6 月 24 日

1 SIFT

可能的替代：

1. 图像微分：一阶 Prewitt、Sobel 检测最大值；二阶 Laplacian 检测过零点。
2. 边缘检测器：Canny：计算梯度、NMS、双阈值提取边缘点、边缘连接。
3. 角点提取：Harris：窗口移动灰度变化，旋转不变，尺度变化。FAST：若灰度比其领域内足够多的像素点的灰度值大或者小。
4. 2D 图像的一些变换：投影变换是最大的集合（即单应矩阵）。

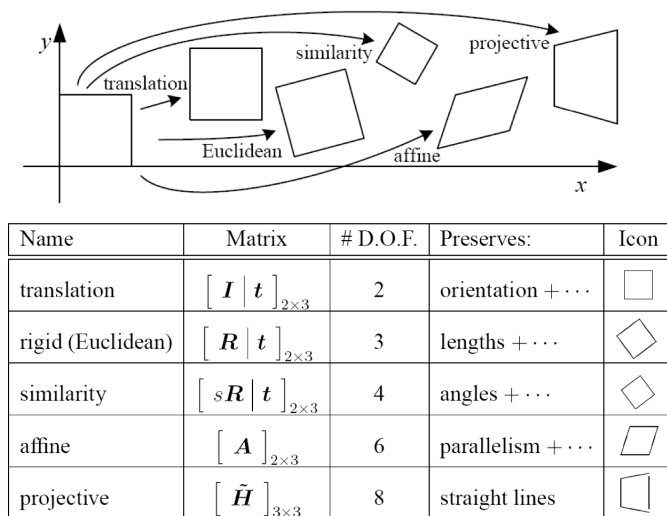


图 1: 2D 图像的一些变换

SIFT 步骤为：多尺度空间（DoG 空间）极值点检测，关键点精确定位，关键点主方向计算，描述子构造。

1.1 特征提取

1. 多尺度空间（为了在尺度变化时特征稳定）：DoG 的做法：在同一个分辨率图像上做不同高斯核的模糊后，然后相减；再把这个方法扩展到多分辨率上。每个分辨率的特征为一个 octave 下的特征，不同的高斯核相减得到的是在该 octave 下不同 layer 的特征。即最后的总特征数为： $\text{octave} \times \text{layer}$ 。

2. 极值点检测：检测上述特征的 26 邻域（ $3 \times 3 \times 3 = 27$ 的方块内，减去自己）是否为极值点。

3. 精确定位：上述都是离散采样不够精确，要对 DoG 进行曲线拟合，即在某一特征图上进行 3 维空间的拟合，根据数值分析的方法可以在计算出三维曲面在某一个极值点的一阶导数和二阶导数，然后一阶导数为 0，得到 ΔX 作为梯度下降的方向，然后逐步收敛到真正的极值点。

4. 去除不稳定的关键点：根据阈值去除对比度低的点；去除边缘点（DoG 中边缘点响应强，但是不稳定。）

1.2 描述子构造

可能的替代点：ORB：快速，存储低；L2-Net。

希望可以构建一个旋转不变，尺度不变且免除光照影响的描述子。

根据上述 DoG 的方案获得关键点，已经具有尺度不变了。接下来考虑旋转不变。首先计算关键点的「梯度方向直方图」，即 x 轴为 $(0, 2\pi)$, y 轴为梯度值的累加。一般 x 轴 2π 分为 10 个 bins，一个 bins 36 度。然后选取直方图中 80% 的 bin 作为主方向，更精细的方向可以插值得到。也可能有多个主方向。

按关键点的主方向旋转后，再使用双线性插值的方法获取 4×4 个子区域，每个子区域分别计算直方图 (8bins)，直方图的值为梯度值的累加，这样对于每个关键点，我们就有了 $4 \times 4 \times 8 = 128$ 维的描述子。当然这个也是按照高斯加权，中间的权重大，附近权重小。

最后把这个描述子按照向量长度进行归一化处理，去除光照的影响（亮度和对比度啥的）。

1.3 匹配过程

可能的替代：ICP (Iterated Closest Points)：如果知道正确的点对应，那么两个点集之间的相对旋转和平移有闭合解，在 ICP 中，假设最近的点为对应点；RANSAC：排除外点。

SIFT 匹配策略：NNDR：最近邻距离比率，定义为最近邻距离和次近邻距离的比值。

SIFT 搜索策略：BBF：回溯检查总是从优先级最高 (best bin) 的树结点开始。

1.4 旋转不变、尺度不变

尺度不变：DoG；旋转不变：梯度直方图；光照影响：描述子归一化。

2 目标检测方法（传统）

2.1 混合高斯模型前景检测

如果已有背景知识，那么利用「背景差法」就可以求出前景：计算当前图像与背景图像的逐像素的灰度差，再通过设置阈值来确定运动前景区域。加入输入的是一个视频流（拍摄同一个地方，但是会不停有人走：静态拍摄，动态场景）。那么我们要对每一个像素点“求均值”，来作为该像素点的背景点像素，一旦有人经过，占据了该像素点，那么这个像素点的值脱离了均值，我们就知道了这是前景。

我们利用混合高斯模型去代表背景点而不是单高斯，因为背景点说不定也是动态的，比如湖边的柳树，同一个点可能一会是柳树，一会是湖面。现在我们只要根据视频的输入来逐步构建高斯混合模型就行了：

• 流程图

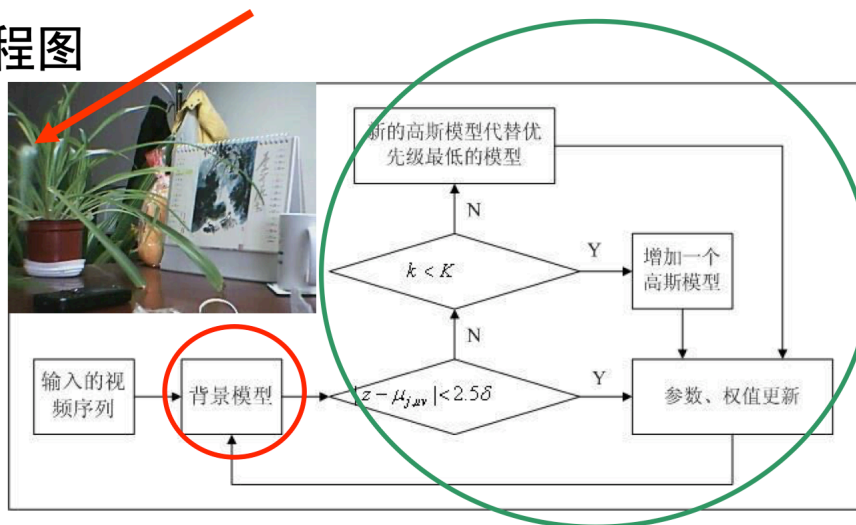


图 2: 前景检测的高斯混合模型步骤

当然也不是所有的混合模型都要使用，如果某些峰值的点频次比较少就去除。

2.2 Adaboost

弱分类器组合成强分类器。对于分类错的样本，加大它的惩罚因子，对于精确率高的弱分类器，加大它的投票权重。每一轮的迭代，都要从给定惩罚因子的数据中去得到一个

最优参数的弱分类器（弱分类器的形式已经给定了，比如说是线性的，但是没有给定线性方程的参数）。

初始化;

For $t = 1$ to T

1. 找到弱分类器:

$$h_t = \operatorname{argmin}_{h_j} \left\{ \varepsilon_j = \sum_{i=1}^m D_t(i) [y_i \neq h_j(x_i)] \right\}$$

2. $\varepsilon_t < 1/2$, 否则终止循环;

3. 计算分类器权重: $\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_t}{\varepsilon_t} \right)$

4. 更新样本权重:

$$D_{t+1}(i) = \frac{D_t(i)}{Z_t} \times \begin{cases} e^{-\alpha_t} & \text{if } h_t(x_i) = y_i \\ e^{\alpha_t} & \text{if } h_t(x_i) \neq y_i \end{cases}$$

输出强分类器:

$$H(x) = \operatorname{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$




图 3: Adaboost 流程

用 Adaboost 去人脸检测：人脸上有许多特征，这些弱特征（鼻子眼睛嘴巴...）可以用已有的弱分类器（如下图的窗口函数）去提取，但是怎么组合这些弱分类器去得到一个强的分类器去检测完整的人脸呢？Adaboost 就可以干这个了。




图 4: Adaboost 人脸检测

3 特定方法的分割

3.1 Mean Shift

核心思想：找到概率密度梯度为零的采样点，并以此作为特征空间聚类的中心点。

步骤如下：

1. 在未标记的点中选一个作为中心 center；
 2. 在一定半径的邻域内，高斯加权后求取新的中心点，然后从原 center 移动到新的 center；
 3. 直至移动的 shift 很小。（即此时的概率密度最高，概率密度梯度为 0）；
 4. shift 过程中遇到的所有点都加入此类别，如果此类别的中心和现有类别中心距离很近，则合并为一个类别；
 5. 从为遍历过的点中选取一个初始点继续迭代。中途难免会有点既在 A 类又在 B 类，那么就看出此点出现的频率划分类别。
 6. 直至遍历所有的点。
- 好处就是与 K-means 相比不需要指定类别个数。缺点是要指定 ball-query 的半径大小。

3.2 Ncut: Normalized Cut

Ncut 是图割 (graph cut) 的升级版。图割只考虑到了将图划分为两个子集，子集之间的相似度最小（连接权重最小），这样会造成只分割出去一个外点。Ncut 则是考虑到了不仅要子集之间权重低，子集内部的相似性要大。

在 Ncut 中：

子集之间的相似性度量为两个子集连接边权重之和；

子集 i 内部的相似性度量为子集 i 和整个集合的连接边权重之和。（这个定义无法直接表述内部的连接性，但是我们都是希望这个值越大越好，即如果只有一个外点的话，这个值很小，但是如果集合 i 的点数比较多，这个值就大。）

$$Ncut(A, B) = \frac{cut(A, B)}{assoc(A, V)} + \frac{cut(A, B)}{assoc(B, V)}$$

其中 $assoc(A, V) = \sum_{u \in A, t \in V} w(u, t)$.

但是 Ncut 是个 NP 难问题，好在可以构建近似解，具体的步骤是：

1. 给定图像点，构建点集 $G(V, E)$ ，点就是像素点，边权重就是像素距离（如果是 RGB 就是三维距离）。
2. 求解 $(D - W)x = \lambda Dx$ 的特征值和对应的特征向量。其中 $W = w_{ij} \in \mathbf{R}^{N \times N}$ 是每个点的相互权重。 $D = diag(d(1), d(2), ..., d(N))$, $d(i) = \sum_j w_{ij}$ 即每个点和其他所有点的权重之和。
3. 次小特征值和其特征向量进行二分类。
4. 如果需要再分，则在分好的类别中重复上述过程。

4 CV 中的机器学习方法

4.1 子空间

为了处理高维度，非结构化数据。

4.1.1 主成分分析法 PCA

寻找投影映射 P ，使得样本从 N 维降到 m 维 ($m < N$)，同时最小化重构平方误差。步骤:

1. 计算样本均值 $\mu = \frac{1}{n} \sum_{i=1}^n x_i$;
2. 计算离散度矩阵 $S = \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$;
3. 离散度矩阵特征值分解，取前 m 个特征值和特征向量 $P \in (N, m)$;
4. 降维 $y_i = P^T(x_i - \mu_i)$.

4.1.2 独立成分分析法 ICA

从多个源信号的线性混合信号中分离出源信号的技术。假设: 源信号统计独立。

4.1.3 线性判别分析方法 LDA

寻找投影 W ，使得投影后的样本类内散度最小，而类间散度最大。

4.2 流形学习

上述都是线性的学习方式，但是我们的数据很多都是非线性的，就要从非线性的角度探讨数据的内在几何结构。

4.2.1 LLE: Locally Linear Embedding

样本空间与内在低维子空间之间在局部意义下的结构可以用线性空间近似。假设嵌入映射在局部是线性的条件下，最小化重构误差。

4.2.2 Isomap 等距映射

之前的版本 MDS 的基本思想: 约简后低维空间中任意两点间的距离应该与它们在原始空间中的距离相同。但是光用欧式距离还不能满足，要考虑“测地距离”，也就是 Isomap 用的方法。

测地距离可以用 Dijkstra 算法求解。

4.2.3 Laplacian Eigenmap

在高维空间中离得很近的点投影到低维空间中的像也应该离得很近。

4.3 稀疏表达

上述方法都无需迭代，转换为求解矩阵特征值；并且探讨了数据的非线性结构；都是非参数方法。但是有个问题，在数据稀疏的时候不太好办。

稀疏表达就是想要求解一个问题，给定一堆稠密的数据 $D = [d_1, d_1, \dots, d_n] \in R^{m \times n} (m \leq n)$ ，如何把他们线性组合后来代表一个给定的稀疏点 $x = D\alpha$ 来代表这群稠密数据？其中 α 的非零点越少越好。

这是个 NP 难问题，但是在 RIP(Restricted Isometry Property) 条件下，可以转化为凸优化。具体不展开了。

$$\begin{aligned} \min_{\alpha} \quad & \|\alpha\|_1 \\ \text{s.t.} \quad & \|x - D\alpha\|_2^2 \leq \varepsilon \end{aligned}$$

可以用来做分类问题，比如给定 C 个类别的图像，然后再给定一张图像要用这 C 个图像线性组合而成，那么最终求的 α 哪一位的值越大，就是哪一类。

4.4 低秩表达

数据矩阵 X 既包含结构信息，也包含噪声，因此可以将矩阵 X 分解为两个矩阵的和，一个是低秩的，另一个是稀疏的。

5 CV 中的优化方法

5.1 稀疏捆绑调整：Sparse BA

这个和 3D CV 中的稀疏重建有关，考完试之后推导学习一下。

5.2 BP

链式法则，这个就不展开了。

5.3 Markov

这个知识点也很重要，考完试之后推导一下。现在只说下大概：HMM 隐马尔可夫->MRF 马尔可夫随机场->CRF 条件随机场。

首先说明：马尔可夫相关的是生成模型，看的是联合分布。条件随机场是判别模型（给一个贴近真实环境的条件概率函数）。

5.3.1 HMM

设 i 时刻的状态为 y_i , 观测为 x_i . 可以想象成从 4 个盒子中摸彩球, 只能看到彩球 (观测), 但是不知道从那个盒子 (状态) 摸出来的。

HMM 有两个基本假设: x_i 只与 y_i 有关; y_i 只与 y_{i-1} 有关。

所以所有状态和观测的联合概率为 ($p(y_1)$ 是给定的初始概率):

$$P(x_1, y_1, \dots, x_n, y_n) = P(y_1) P(x_1 | y_1) \prod_{i=2}^n P(y_i | y_{i-1}) P(x_i | y_i)$$

通过这个联合分布我们可以看出三个未知的东西: 初始状态概率 $p(y_1)$, 所有的状态转移概率 $p(y_i | y_{i-1})$, 所有的观测概率 $p(x_i | y_i)$ 。这些东西一起成为模型参数。

现在我们可以定义 HMM 的三个基本问题:

- 概率计算问题: 根据模型参数推导某一种观测序列 $\{x_i\}$ 的概率。
- 学习问题: 根据观测序列 $\{x_i\}$, 估计模型参数。
- 预测问题: 根据模型和观测序列 $\{x_i\}$, 求最有可能的状态序列 $\{y_i\}$ 。

求解这些可以用 Baum-Welch, Viterbi 算法 (前向后向算法的改进: 引入 DP)。

5.3.2 MRF 和 CRF

HMM 是有向图, 联合概率的形式很好定义: 直接相乘。那么 MRF 是个无向图, 怎么定义联合概率分布呢?

MRF 引入了团 (集合中任意两个节点都互相连接即为团) 和势函数 (满足非负性, 一般为指数函数) 去定义联合概率分布。

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{Q \in \mathcal{C}} \psi_Q(\mathbf{x}_Q)$$

Z 为规范化因子。

CRF 就是给定观测 x_i 后状态变量 y_j 的 MRF。CRF 一般考虑线性链式的 CRF, 如下图所示:




图 5: CRF

6 附录